

# Aula Prática 5.

Saturday, May 29, 2021 11:39 AM

## Método de Gram-Schmidt (Notas de Aula 14)

Entrada:  $A_{m \times n}$  com colunas LI

• Inicializar  $Q_{m \times n}$  e  $R_{n \times n}$

De  $j=1$  até  $n$ :

$v = a_j$

De  $i=1$  até  $j-1$ :

$$r_{ij} = q_i^T a_j$$


$$v = v - r_{ij} q_i$$

fim

$$r_{jj} = \|v\|$$

$$q_j = v / r_{jj}$$

fim



Gram-Schmidt modificado:  $r_{ij} = q_i^T v$

Teste de ortogonalidade:  $A = \text{rand}(5,5)$

Analisar e comparar  $\|Q^T A - I\|$

Teste de precisão:  $\|A - QR\|$  pequena

É esperado que essas medidas sejam próximas de zero, porém, você pode usá-las diferentes métodos aplicados em uma mesma matriz.

## ③ Pivoteamento de Colunas

No passo 1, toma-se  $v$  como a coluna de maior norma, e  $q_1 = v / \|v\|$

(faz-se então a troca de colunas em  $A$  e  $P$ , que é iniciada como  $I_{n \times n}$ )

De  $j=2$  até  $j=n$ :

$$A(:,j:n) = A(:,j:n) - \text{proj}_{q_{j-1}} A(:,j:n)$$

$$k = (j-1) + \text{argmax}_l \|A(:,l)\|, l = j, j+1, \dots, n$$

↳ coluna de maior projeção

Ao encontrar  $k$ :

$$A(:,j) \xleftrightarrow[\text{trocar}]{\text{colunas}} A(:,k)$$

$$R(:,j) \leftrightarrow R(:,k)$$

$$P(:,j) \xleftrightarrow[\text{trocar}]{\text{colunas}} P(:,k)$$

$$v = A(:,j)$$

$$R_j = q_j^T A$$

$$q_j = v / \|v\|$$

usado na iteração seguinte.

Saída:  $Q, R, P$  tal que  $AP = QR$

$$A(:,j:n) - \text{proj}_{q_{j-1}} A(:,j:n) = A(:,j:n) - \frac{(q_{j-1}^T A(:,j:n))}{q_{j-1}^T q_{j-1}} q_{j-1}$$

$$= [q(q^T A(:,j:n))] = \begin{bmatrix} q_1 \\ \vdots \\ q_{j-1} \end{bmatrix} [q_1^T a_j \quad q_1^T a_{j+1} \quad \dots \quad q_1^T a_n]$$

Verificando dimensões

$$q(q^T A(:,j:n))$$

$$(m \times 1) (1 \times m) (m \times (n-j+1))$$

$$m \times 1 (1 \times (n-j+1))$$

$$m \times (n-j+1)$$

Mesma dimensão de  $A(:,j:n)$

Adaptação do Pseudo código de

Gilbert Strang, "Linear Algebra and Learning from data" p.130-131

Dicas de comandos:  $A \rightarrow$  matriz  $m \times n$

•  $\text{sum}(A.^2, 1)$

↳ retorna  $[\|a_1\|^2, \|a_2\|^2, \dots, \|a_n\|^2]$

•  $[m, k] = \text{max}(v)$  → retorna máximo e índice do máximo

•  $\text{diag}(A^T A) \rightarrow [\|a_1\|^2, \|a_2\|^2, \dots, \|a_n\|^2]$

$$\begin{bmatrix} -a_1^T & - \\ -a_2^T & - \\ \vdots & \vdots \\ -a_n^T & - \end{bmatrix} \begin{bmatrix} a_1 & a_2 & \dots & a_n \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} = \begin{bmatrix} a_1^T a_1 & a_1^T a_2 & \dots & a_1^T a_n \\ \vdots & \vdots & \ddots & \vdots \\ a_n^T a_1 & a_n^T a_2 & \dots & a_n^T a_n \end{bmatrix}$$

• Troca de colunas:  $A(:, [i \ j]) = A(:, [j \ i])$



# Aula Prática 5

Saturday, May 29, 2021

12:37 PM

## ④ Método de Householder

Algoritmo (Notas de aula 17)

Entrada:  $A_{m \times n}$

Saída:  $U_{m \times n} \rightarrow$  vetores unitários ( $u$ ) que geram os refletores.

$R_{m \times n}$   $\rightarrow$  triangular superior

Inicializa-se  $U$  com zeros

De  $k=1$  até  $n$   $\rightarrow$  pense um pouco

$x = A_{k:m, k}$

Se  $x(1) < 0$ :

$$x(1) = x(1) - \|x\|$$

Se não:

$$x(1) = x(1) + \|x\|$$

$x - Hx$

$$\begin{bmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \end{bmatrix}$$

o que acontece na última iteração!

$$u = x / \|x\|$$

$$U(k:m, k) = u$$

$$A(k:m, k:n) = A(k:m, k:n) - 2u(u^T A(k:m, k:n))$$

$$HA = (I - 2uu^T)A = A - 2uu^TA$$

Fim

$\downarrow$

$\hookrightarrow$  passo de triangularização

$$R = \text{triu}(A)$$

Fim

Sugestões: Script que gera matrizes quadradas de ordens diferentes (10, 100, 500, 1000, ...)  
aplica os métodos e compara ortogonalidade ( $\|Q^T Q - I\|$ ) e opionalmente precisão ( $\|A - QR\|$ )

## ⑤ Função Espectro.

Entrada:  $A$  simétrica (quadrada)

$\text{tol} \rightarrow$  tolerância

$$\underline{[Q \ R]} = \underline{\text{qr}(A)}$$

$\hookrightarrow$  Use seu algoritmo preferi

s a

(proibido usar qr nativo Scilab)

$$A_1 = RQ;$$

$$\underline{[Q_1, R_1]} = \underline{\text{qr}(A_1)}$$

$\vdots$

$$A_k = R_{k-1} Q_{k-1}$$

$A_k$  é semelhante à  $A$

Critério de parada:  $\|\underline{\text{diag}(A_k)} - \underline{\text{diag}(A_{k-1})}\|_{\infty} < \text{tol}$

$A_k \rightarrow$  triangular superior

$$\begin{bmatrix} a_{11}-\lambda & * & * & * \\ 0 & a_{22}-\lambda & * & * \\ & 0 & \ddots & * \\ & & 0 & a_{nn}-\lambda \end{bmatrix}$$

$$\det(A_k - \lambda I) = (a_{11} - \lambda)(a_{22} - \lambda) \dots (a_{nn} - \lambda)$$

Raízes:  $\text{diag}(A_k)$